

Tehnici de optimizare

Laborator 1: Introducere in toolbox-ul de optimizare Matlab

1 Introducere

Formularea standard a unei probleme de optimizare:

$$\begin{aligned} f^* = \min_{x \in \mathbb{R}^n} \quad & \text{sau } \max_{x \in \mathbb{R}^n} f(x) \\ \text{s.l.:} \quad & Cx \leq d, \quad g(x) \leq 0 \\ & Ax = b, \quad h(x) = 0 \\ & x \in S \end{aligned} \tag{1}$$

unde:

- x - variabila de decizie
- $f(x)$ - functia obiectiv
- S - multimea fezabila de baza (de exemplu $S = [a, b]$ -se mai numeste si constrangere de tip box)
- $Cx \leq d, g(x) \leq 0$ - constrangeri de inegalitate
- $Ax = b, h(x) = 0$ - constrangeri de egalitate
- $P = \{x \in S \mid Ax = b, h(x) = 0, Cx \leq d, g(x) \leq 0\}$ - multimea fezabila
- x^* - punctul de optim
- $f^* = f(x^*)$ -valoarea de optim

O clasificare naturala a problemelor de minimizare este:

1. **Probleme fara constrangeri:** $\min_{x \in \mathbb{R}^n} f(x)$.

In acest caz, multimea fezabila este spatiul Euclidian \mathbb{R}^n

2. **Probleme cu constrangeri:** Formularea problemei 1

Dupa natura functiei obiectiv, mai putem identifica urmatoarele tipuri de probleme:

- **Problema LP** (eng. *Linear Programing*): functia obiectiv si constrangerile sunt lineare.
- **Problema QP** (eng. *Quadratic Programing*): functia obiectiv este patratica si constrangerile sunt liniare

1.1 Probleme fara constrangeri



$x = \text{fminunc}(\text{fun}, x_0)$ - returneaza un punct de minim local al functiei fun , cu ajutorul informatiei de ordinul I (gradient) si a celei de ordin II (Hessiana).

Variabila fun reprezinta functia obiectiv diferentiabila ce trebuie furnizata ca o variabila de tip *function handle*. O variabila de tip *function handle* poate fi, e.g. un fisier `objfun.m` care primeste la intrare variabila de decizie x si returneaza valoarea functiei in x . Vectorul x_0 reprezinta punctul initial de unde porneste procesul de cautare al minimului.

Pentru mai multe detalii, apelati la una din cele doua comenzi ajutatoare din Matlab: **help** si **doc**.

Exemplu: Consideram problema de optimizare:

$$\min_{x \in \mathbb{R}^2} f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$

Sa se rezolve problema (sa se gaseasca un punct de minim local) utilizand rutina `fminunc`, cu punctul de initializar $x_0 = \begin{bmatrix} -1 \\ 2 \end{bmatrix}$

Solutie: Se creaza fisierul `objfun.m` ce va contine:

```
function f=objfun(x)
f = 100*(x(2)-x(1)^2)^2 + (1-x(1))^2;
```

Se apeleaza rutina `fminunc` in urmatoarul mod:

```
x0=[-1;2];
x=fminunc(@objfun,x0)
```

Gasiti in anexa versiunea in care functia este declarata in acelasi fisier cu `fminunc`.

1.2 Probleme cu constrangeri



$x = \text{fmincon}(\text{fun}, x_0, \text{C}, \text{d}, \text{A}, \text{b}, \text{l}, \text{u}, \text{nonlcon}, \text{optiuni})$ - returneaza un punct de minim local pentru problema de optimizare 1

Variabila **fun** reprezinta functia obiectiv ce trebuie furnizata ca o variabila de tip *function handle*.

Matricele si vectorii **C**, **d**, **A**, **b**, **l**, **u** definesc *constrangerile liniare* cu structura prezentata in modelul 1 -cu mentiunea ca S este o constrangere de tip box ($l \leq x \leq u$)

Variabila de tip *handle* **nonlcon** returneaza *constrangerile neliniare* de egalitate si inegalitate reprezentate in 1 (adica $g(x)$ si $h(x)$);

Vectorul x_0 reprezinta *punctul initial* de unde porneste procesul de cautare al minimumului

Variabila **optiuni** reprezinta setul de optiuni specific fiecărei rutine MATLAB. Comanda `optiuni=optimset('fmincon')` afiseaza setul de optiuni implicit. Fiecare dintre acestea se poate modifica in functie de problema de minimizare.

Pentru mai multe detalii, apelati: **help fmincon**.

Exemplu: Consideram problema de optimizare:

$$\begin{aligned} \min_{x \in \mathbb{R}^2} f(x) \quad & (= e^{x_1} (4x_1^2 + 2x_2^2 + 4x_1x_2 + 2x_2 + 1)) \\ \text{s.l.: } g(x) \leq 0 \quad & \left(\begin{cases} x_1x_2 - x_1 - x_2 + 1.5 \leq 0 \\ -x_1x_2 - 10 \leq 0 \end{cases} \right) \end{aligned}$$

Sa se rezolve local problema utilizand rutina `fmincon`, cu punctul de initializare $x_0 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

Solutie: Se creeaza fisierul `objfun.m` ce defineste functia obiectiv si `confun.m` in care se definesc constrangerile:

```
function f=objfun(x)
f=exp(x(1))*(4*x(1)^2+2*x(2)^2+4*x(1)*x(2)+2*x(2)+1);

function [g,h]=confun(x)
g=[x(1)*x(2)-x(1)-x(2)+1.5 -x(1)*x(2)-10];
h=[];
```

Apoi se apeleaza rutina pentru minimizare cu restrictii:

```
x0=[-1,1];
optiuni=optimset(fmincon);
optiuni.LargeScale=off;
x=fmincon(@objfun,x0,[],[],[],[],[],[],@confun,optiuni)
```

1.3 Problema LP



$x = \text{linprog}(c,C,d,A,b,lb,ub,x_0,\text{optiuni})$ - rezolva probleme de programare liniara, ce vizeaza minimizarea unei functii obiectiv liniare, in prezenta unui set de constrangeri liniare.

O problema de programare liniara are urmatoarea formulare standard:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} c^T x \\ \text{s.l.: } Cx \leq d \\ Ax = b \\ lb \leq x \leq ub \end{aligned} \tag{2}$$

unde $c, lb, ub \in \mathbb{R}^n, d \in \mathbb{R}^m, b \in \mathbb{R}^p, C \in \mathbb{R}^{m \times n}, A \in \mathbb{R}^{p \times n}$

Exemplu: Formulati problema LP pentru o clasificare binara si rezolvati problema utilizand functia linprog.

Solutie: Clasificarea binara constituie procesul de separare a elementelor unui set in doua grupuri pe baza unei reguli de clasificare. Astfel ca pentru clasificarea unei multimi de dimensiune $N(\{(z_1, y_1), \dots, (z_N, y_N)\})$ operam cu urmatoarele notiuni:

- $z_i \in \mathbb{R}^n$ - vectorul de caracteristici al instantei i ($z \in \mathbb{R}^{N \times n}$);
- $y_i \in \{-1, 1\}$ - eticheta unei instantei i ;

Presupunem pentru simplitate ca setul de date este impartit in:

- primele n_1 date pentru $y = 1$,
- restul $n_2 = N - n_1$ pentru $y = -1$

Aceasta ipoteza este usor realizabila in etapa de prelucrare a datelor.

Pentru regula de clasificare, consideram ca setul de date este separabil linear (vezi figura 1) si introducem *teorema de separare a hiperplanelor*:

Fie doua multimi A si B , subseturi convexe ¹ din \mathbb{R}^n . Daca $\exists w \in \mathbb{R}^n$ nenul si un numar real b astfel incat

$$\begin{aligned} w^T x &\geq b, \quad \forall x \in A \\ w^T y &\leq b, \quad \forall y \in B \end{aligned}$$

atunci hiperplanul $w^T z = b, \forall z \in A \cup B$ separa cele doua multimi A si B




Figure 1: Stanga: 2 multimi separabile linear; Dreapta: multimi nelinear separabile

Asadar avem regula de clasificare:

$$\begin{cases} w^T z_i - b \geq 0, \forall y_i = 1 \\ w^T z_j - b \leq 0, \forall y_j = -1 \end{cases} \quad (3)$$

Prin prisma acestei alegeri, gasirea clasificatorului binar se echivaleaza cu gasirea ponderilor $w = [w_1, \dots, w_n]^T$ si a deplasarii b ce definesc hiperplanul de separare $w^T z - b = 0$.

Intrucat inegalitatile din 3 sunt omogene, le putem rescrie:

$$\begin{cases} w^T z_i - b \geq t, \forall y_i = 1 \\ w^T z_j - b \leq -t, \forall y_j = -1 \end{cases} \quad (4)$$

¹Detalii despre aceasta notiune la curs

Deoarece dorim un t cat mai mare, problema LP se formuleaza astfel:

$$\begin{aligned} & \max_{w,b,t} t \\ & \text{s.l.: } w^T z_i - b \geq t, \forall y_i = 1 \\ & \quad w^T z_j - b \leq -t, \forall y_j = -1 \end{aligned} \quad (5)$$

Observatie! Putem remarca ca functiile Matlab rezolva in general probleme de minimizare, astfel ca trebuie sa aducem problema de maximizare la una de minimizare. Acest lucru este posibil, intrucat avem urmatoarea relatie: $\max f(x) = -\min -f(x)$.

Formulara din 5 trateaza cazul cand cele doua multimi sunt complet separabile. Dar aceasta situatie este un caz ideal, rar intalnit in realitate. Astfel ca s-a introdus o relaxare a constrangerilor 4 ($t = 1$):

$$\begin{cases} w^T z_i - b \geq 1 - u_i, \forall y_i = 1 \\ w^T z_j - b \leq -(1 - v_j), \forall y_j = -1 \end{cases}$$

pentru $\forall u_i, v_j \geq 0$. Observam ca pentru $u = v = 0$ recuperam cazul separabil. Prin urmare dorim vectorii u si v sa fie cat mai mici:

$$\begin{aligned} & \min_{w,b,u,v} 1^T u + 1^T v \\ & \text{s.l.: } w^T z_i - b \geq 1 - u_i, \forall y_i = 1 \\ & \quad w^T z_j - b \leq -(1 - v_j), \forall y_j = -1 \\ & \quad u \geq 0; v \geq 0 \end{aligned} \quad (6)$$

Pentru un grad de generalitate mare, vom apela functia `linprog` pentru problema 6. Comparam forma acesteia cu forma standard LP 2 si obtinem:

$$\text{Variabila de decizie } x = \begin{bmatrix} w \\ b \\ u \\ v \end{bmatrix} \in \mathbb{R}^{(n+1+N)}, c = \begin{bmatrix} \text{zeros}(n, 1) \\ 0 \\ \text{ones}(N, 1) \end{bmatrix}.$$

Restrictii de egalitate nu avem deci $A = []$, $b = []$.

Constrangerile de inegalitate trebuiesc prelucrate:

$$\begin{cases} w^T z_i - b \geq 1 - u_i, \forall y_i = 1 \\ w^T z_j - b \leq -(1 - v_j), \forall y_j = -1 \end{cases} \Rightarrow \begin{cases} -w^T z_i + b - u_i \leq -1, \forall y_i = 1 \\ w^T z_j - b - v_j \leq -1, \forall y_j = -1 \end{cases}$$

Deci:

$$C = \begin{bmatrix} -z(1 : N/2, :) & \text{ones}(N/2, 1) & -I_{N/2} & O_{N/2} \\ z(N/2 + 1 : N, :) & -\text{ones}(N/2, 1) & O_{N/2} & -I_{N/2} \end{bmatrix}, d = -\text{ones}(N, 1)$$

Pentru x nu avem un prag superior, astfel ca $u = []$, dar pentru u si v avem conditiile

$$u \geq 0 \text{ si } v \geq 0. \text{ Prin urmare } l = \begin{bmatrix} -\text{inf} \\ \vdots \\ -\text{inf} \\ \text{zeros}(N, 1) \end{bmatrix} \in \mathbb{R}^{(n+1+N) \times 1}$$

In final apelam: $x = \text{linprog}(c, C, d, A, b, l, u)$.

1.4 Problema QP



$x = \text{quadprog}(Q, q, C, d, A, b, l, u, x_0, \text{optiuni})$ - rezolva probleme de programare patratică, ce vizează minimizarea unei funcții obiectiv patratică, în prezența unui set de constrângeri liniare.

O problema de programare patratică are următoarea formulare standard:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} & \frac{1}{2} x^T Q x + q^T x \\ \text{s.l.: } & Cx \leq d \\ & Ax = b \\ & l \leq x \leq u \end{aligned} \quad (7)$$

unde $Q = Q^T \in \mathbb{R}^{n \times n}$, $q, l, u \in \mathbb{R}^n$, $d \in \mathbb{R}^m$, $b \in \mathbb{R}^p$, $C \in \mathbb{R}^{m \times n}$, $A \in \mathbb{R}^{p \times n}$

Exemplu: Formulati problema QP pentru un clasificator binar și rezolvați-o utilizând funcția `quadprog`.

Soluție: Definim ca și în exemplul din secțiunea LP

- N - numărul de date
- $z_i \in \mathbb{R}^n$ - vectorul caracteristic instanței i ($z \in \mathbb{R}^{N \times n}$)
- $y_i \in \{-1, 1\}$ eticheta instanței i

De asemenea presupunem că datele sunt separabile linear și că sunt aranjate astfel: primele $N/2$ date sunt etichetate cu 1 și restul cu -1

Introducem pentru regula de separare tehnica *Support Vector Machine* (SVM). Aceasta calculează parametri hiperplanului de separare cu ajutorul vectorilor suport, de unde și numele algoritmului de învățare automată. Vectorii de suport sunt acele puncte de date cele mai apropiate de hiperplanul de separare (a se vedea figura 2). Atenția asupra acestora este motivată de faptul că ele sunt cele mai greu de clasificat.

Asadar facem următoarea notatie:

- $H_1 : w^T z - b = 1$ -dreapta pe care se găsesc punctele etichetate cu 1 și cele mai apropiate de hiperplanul de separare;
- $H_2 : w^T z - b = -1$ -dreapta pe care se găsesc punctele etichetate cu -1 și cele mai apropiate de hiperplanul de separare;

Scopul SVM-ului este de a găsi hiperplanul care oferă cea mai bună margine, adică cea mai mare distanță dintre H_1 și H_2 . Cum găsim această margine? Pentru aceasta amintim distanța de la un punct z_i la o dreaptă $w^T z - b$:

$$d = \frac{|w^T z_i - b|}{\|w\|}$$

Astfel distanța de la un punct z_+ de pe H_1 la hiperplanul de separare este

$$d_+ = \frac{|w^T z_+ - b|}{\|w\|} = \frac{|1|}{\|w\|} = \frac{1}{\|w\|}$$




Figure 2: Rezentarea SVM pentru $z \in \mathbb{R}^2$ (punctele albastre au eticheta -1 , iar cele portocalii 1)

Procedand in aceeași maniera pentru punctele de pe H_2 obținem:

$$d_- = \frac{|w^T z_- - b|}{\|w\|} = \frac{|-1|}{\|w\|} = \frac{1}{\|w\|}$$

Prin urmare găsim că marginea este: $d_+ + d_- = \frac{2}{\|w\|}$

Cu condiția că nu avem puncte între H_1 și H_2 rescriem relația 3:

$$\begin{cases} w^T z_i - b \geq 1, \forall y_i = 1 \\ w^T z_j - b \leq -1, \forall y_j = -1 \end{cases} \Rightarrow \begin{cases} y_i(w^T z_i - b) \geq 1 \\ y_j(w^T z_j - b) \geq 1 \end{cases}$$

Asadar am găsit problema de optimizare:

$$\begin{aligned} \max_{w,b} \frac{2}{\|w\|} & \Leftrightarrow \min_{w,b} \frac{\|w\|^2}{2} \\ \text{s.l.: } y(w^T z - b) & \geq 1 \quad \text{s.l.: } y(w^T z - b) \geq 1 \end{aligned} \tag{8}$$

Echivalența problemelor este susținută de faptul că maximizarea $\frac{2}{\|w\|}$ presupune găsirea celui mai mic w . Remarcăm că problema obținută este un QP.

Continuăm prin a rescrie problema 8 pentru cazul neseparabil, relaxând restricțiile:

$$\begin{aligned} \min_{w,b,v} \frac{1}{2} \|w\|^2 + \lambda 1^T v \\ \text{s.l.: } y_i(w^T z_i - b) & \geq 1 - v_i, i = 1 : N \\ v & \geq 0, \end{aligned} \tag{9}$$

unde $\lambda \in \mathbb{R}$ este o pondere care decide influența componentei liniare din funcția obiectiv.

Comparând 9 cu formularea standard 7 găsim:

Variabila de decizie $x = \begin{bmatrix} w \\ b \\ v \end{bmatrix} \in \mathbb{R}^{(n+1+N)}$

Functia obiectiv: $Q = \begin{bmatrix} I_n & O_n \\ O_{1+N} & O_{1+N} \end{bmatrix}, \quad q = \lambda \begin{bmatrix} \text{zeros}(n, 1) \\ 0 \\ \text{ones}(N, 1) \end{bmatrix}.$

Restrictii de egalitate nu avem deci $A = [], b = []$.

Constrangerile de inegalitate trebuiesc prelucrate:

$$y_i(w^T z_i - b) \geq 1 - v_i, \forall i = 1 : N \Rightarrow -y_i w^T z_i + y_i b - v_i \leq -1, \forall i = 1 : N$$

Deci: $C = [-y.*z(1:N,:) \quad y \quad -I_N], d = -\text{ones}(N, 1)$

Pentru x nu avem un prag superior, astfel ca $u = []$, dar pentru v avem conditia $v \geq 0$.

Prin urmare $l = \begin{bmatrix} -inf \\ \vdots \\ -inf \\ \text{zeros}(N, 1) \end{bmatrix} \in \mathbb{R}^{(n+1+N) \times 1}$

In final apelam: $x = \text{quadprog}(Q, q, C, d, A, b, l, u)$

2 Aplicatii

1. Exersati comenzile *fmincon* si *fminunc* implementand exemplele din sectiunile 1.1 si 1.2 din laborator.
2. Fie setul de date de mai jos:
unde

z^1	0	0	1	2	1	4	1	2	3	4	14	12	10	13	14	14	1	7	9	6
z^2	5	1	1	0	2	6	3	3	2	5	10	5	10	8	8	6	24	8	10	10
y	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	1	1	1	1	1	1	1	1	1	1

- z^1 reprezinta numarul de prezente al unui student la curs;
- z^2 este numarul de ore dedicate proiectului de catre student;
- y este eticheta studentului cu semnificatia -1 pentru picat, respectiv 1 pentru promovat;

Cerinte:

- Plotati setul de date. Cum este acesta?
- Calculati clasificatorul din formularea LP pentru cazul neseparabil si plotati hiperplanul de separare gasit. Adaugati punctele $[z^1, z^2, y] = \{[2; 5; -1], [15; 11; -1]\}$; si recalculati clasificatorul. Ce puteti spune despre u si v ?
- Calculati clasificatorul din formularea QP cu $c = 0.001$ pentru cazul neseparabil si plotati hiperplanul de separare gasit. Schimbati valoarea lui $\lambda = \{0.1; 1\}$ si recalculati clasificatorul. Ce observati?

3 Anexa

3.1 Probleme fara constrangeri

```

1 %% fminunc
2 % min: 100*(x2-x1^2)^2 + (1-x1)^2
3 % x0 = [-1,2]
4 %%
5 f = @(x) 100*(x(2) -x(1)^2)^2 + (1 -x(1))^2;
6 x0 = [-1 2];
7 sol =fminunc(f,x0)

```